Determinantes económicos, sociales y demográficos de la migración en Colombia: Un enfoque probabilístico y machine learning (2022-2025)

Alan Steven Ríos Munar

Juan Esteban Samaniego Poveda

Sebastian Casas Poloche

Universidad Externado de Colombia

IA con aplicaciones en economía

Lina María Castro

2026

Introducción

La migración interna en Colombia es un fenómeno que ha estado presente a lo largo del tiempo y que tiene importantes implicaciones económicas, sociales y territoriales. Las decisiones de migrar no ocurren de manera aleatoria, sino que están influenciadas por diferentes factores como las oportunidades laborales, el acceso a educación, las condiciones de vida y en algunos casos, la violencia o la inseguridad en determinadas regiones.

De acuerdo con esto, principalmente se quiere analizar los determinantes de la migración interna en Colombia, con el fin de identificar qué características tienen las personas que deciden cambiar de municipio o región. A través de este análisis, se pretende comprender mejor las dinámicas de movilidad poblacional en el país y aportar evidencia que permita interpretar este fenómeno desde una perspectiva económica y social.

Fuentes de información

Para el análisis se utilizaron los microdatos de la Gran Encuesta Integrada de Hogares (GEIH) del DANE, correspondientes a los años 2022, 2023, 2024 y 2025. La inclusión de 2022 permitió ampliar la base de datos y contar con un mayor número de observaciones, lo que facilita la identificación de patrones más consistentes en el tiempo.

La GEIH es una fuente clave para el análisis socioeconómico en Colombia, ya que ofrece información detallada sobre características demográficas, laborales e ingresos, así como variables relacionadas con la migración, como cambios de residencia y motivos de traslado. Esto permite abordar el fenómeno desde una perspectiva económica y territorial más completa.

Integración de datos

El proceso de construcción de la base de datos implicó la integración de la información de los diferentes años analizados. Dado que la GEIH está organizada por periodos mensuales, fue necesario consolidar las bases en una estructura unificada que permitiera trabajar la información de forma conjunta.

Para ello, se realizó una homologación de variables, asegurando consistencia en nombres, formatos y tipos de datos entre los años, lo que garantizó la comparabilidad de la información. Finalmente, se unificaron las bases en un solo conjunto, facilitando su manejo y permitiendo un análisis más robusto de la migración interna en Colombia.

Limpieza y preparación de los datos

Una vez integrada la base de datos, se realizó un proceso de limpieza y preparación con el fin de mejorar la calidad de la información. En primer lugar, se identificaron y trataron los valores faltantes mediante criterios definidos según la naturaleza de cada variable, y se eliminaron registros cuando fue necesario. Asimismo, se revisaron posibles duplicados y se corrigieron formatos y tipos de datos para garantizar su consistencia.

Este proceso es fundamental, ya que asegura que el análisis se base en información confiable y adecuada. Una correcta depuración y organización de los datos reduce errores y sesgos, facilitando la aplicación de técnicas de análisis de manera más precisa en el estudio de la migración.

Análisis exploratorio de los datos (EDA)

1. Distribución por sexo (1 = grupo base, 2 = dummy)

La gráfica muestra una distribución bastante equilibrada entre los dos grupos de la variable sexo_2, con una ligera mayor proporción del grupo base (False) frente al grupo dummy (True). Aproximadamente, el grupo base representa cerca del 53–54% de la muestra, mientras que el grupo dummy se sitúa alrededor del 46–47%. Aunque no existe un desbalance significativo, esta pequeña diferencia sugiere una leve sobrerrepresentación de uno de los grupos, lo cual debe tenerse en cuenta al interpretar los resultados, especialmente si el sexo está relacionado con otras variables relevantes del análisis.

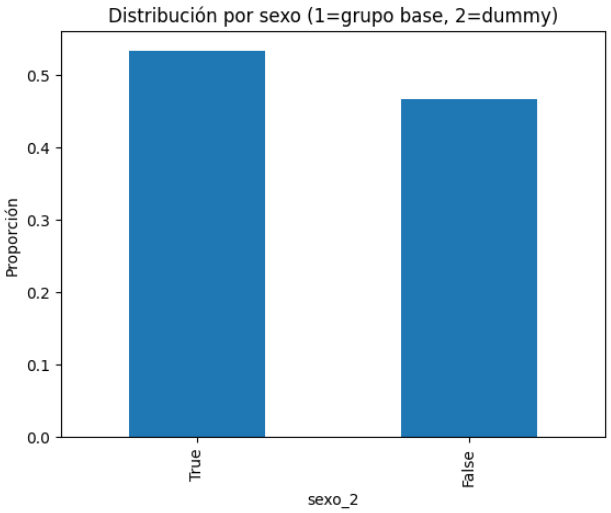

2. Ingreso según sexo (log)

El diagrama de dispersión del ingreso en escala logarítmica El gráfico muestra que ambas categorías de sexo presentan distribuciones muy similares en el ingreso (en escala logarítmica), con la mayoría de los valores concentrados entre aproximadamente 10 y 18. No se observan diferencias visuales claras entre los grupos, lo que sugiere que no hay una brecha evidente de ingresos en este análisis descriptivo. También se identifican algunos valores atípicos en ambos grupos, especialmente en niveles bajos, lo que podría estar asociado a ingresos muy reducidos o inconsistencias en los datos. En general, estos resultados indican que el ingreso no presenta diferencias marcadas por sexo a nivel visual.

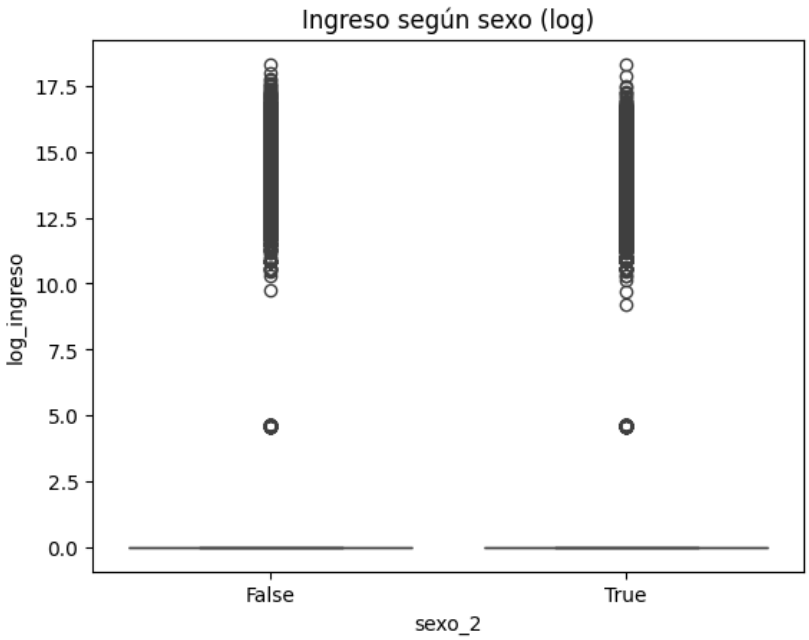

3. Proporción de migrantes

El gráfico de barras evidencia un marcado desbalance en la variable de migración, con una proporción cercana al 99% de individuos que no migran frente a apenas un 1% que sí lo hace. Esto confirma que la migración es un evento poco frecuente dentro de la muestra analizada. Este comportamiento implica que la información disponible sobre migrantes es limitada en comparación con los no migrantes, lo que puede influir en los resultados del análisis y en el desempeño de los modelos. Por ello, es importante tener en cuenta esta asimetría al interpretar los resultados y al evaluar la capacidad explicativa de las variables.

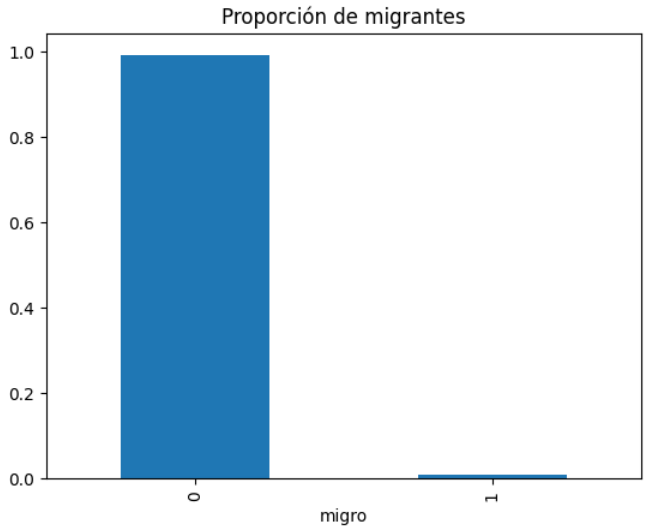

4. Edad según cotización a pensión

El boxplot muestra diferencias claras en la edad entre quienes cotizan a pensión y quienes no. Las personas que cotizan presentan edades más altas, con una mediana cercana a los 40 años, mientras que quienes no cotizan tienen una mediana más baja, alrededor de los 30 años. Esto sugiere que la cotización está asociada a etapas más avanzadas del ciclo laboral. Además, el grupo que no cotiza presenta mayor dispersión y valores muy bajos de edad, lo que indica la presencia de jóvenes fuera del sistema. En contraste, los cotizantes muestran una distribución más concentrada en edades productivas, coherente con el funcionamiento del mercado laboral.

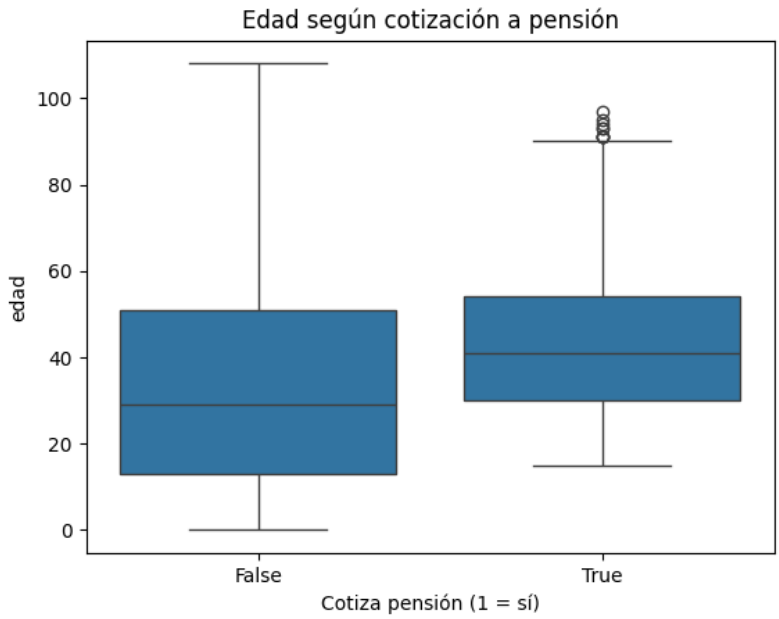

5. Cotización a pensión según sexo

La gráfica evidencia una diferencia importante en la proporción de cotización a pensión entre los grupos de sexo. El grupo base (False) presenta una tasa cercana al 29%, mientras que el grupo dummy (True) se ubica alrededor del 18–19%, lo que indica una brecha significativa entre ambos. Está diferencia sugiere que el sexo está asociado con desigualdades en la participación en el sistema pensional, posiblemente relacionadas con condiciones del mercado laboral. Además, en ambos casos la proporción de cotizantes es relativamente baja, lo que refleja una limitada cobertura del sistema.

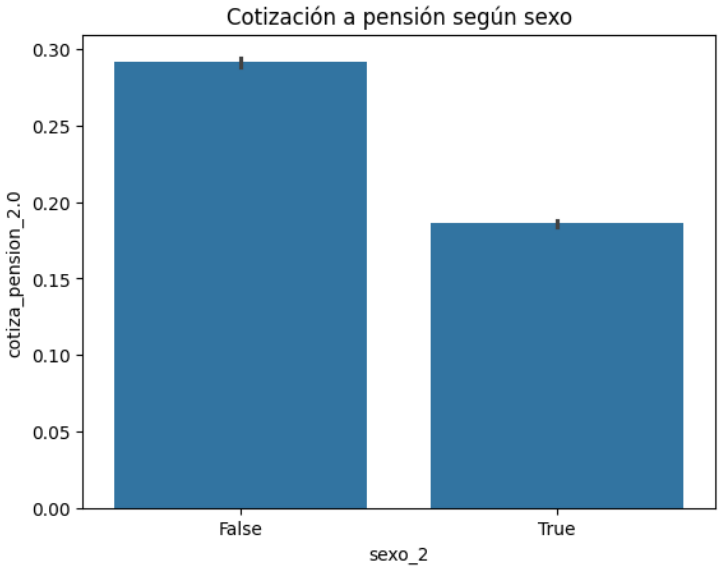

6. Relación edad e ingreso

La gráfica muestra una relación positiva pero débil entre la edad y el ingreso (en escala logarítmica). Aunque se observa una ligera tendencia a mayores ingresos entre los 25 y 60 años, la alta dispersión indica que la edad por sí sola no explica bien el nivel de ingreso.Además, se identifican valores atípicos en niveles bajos de ingreso, lo que podría reflejar desempleo, ingresos nulos o inconsistencias en los datos. En general, la relación es poco concluyente y sugiere que otras variables influyen de manera más relevante en los ingresos.

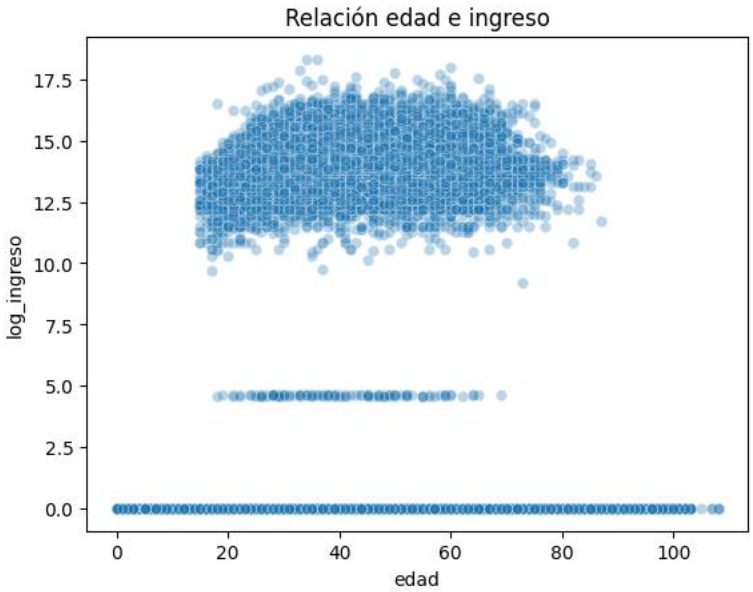

7. Ingreso según horas extra

El diagrama de caja muestra que quienes reciben horas extra presentan una mediana de ingreso más alta y una distribución concentrada en niveles superiores, lo que indica mayores ingresos en este grupo. Además, se observa una mayor dispersión en los valores altos. Por el contrario, quienes no reciben horas extra tienen ingresos más bajos y mayor presencia de valores atípicos en la parte inferior. Esto sugiere que el pago de horas extra está asociado a mejores niveles de ingreso

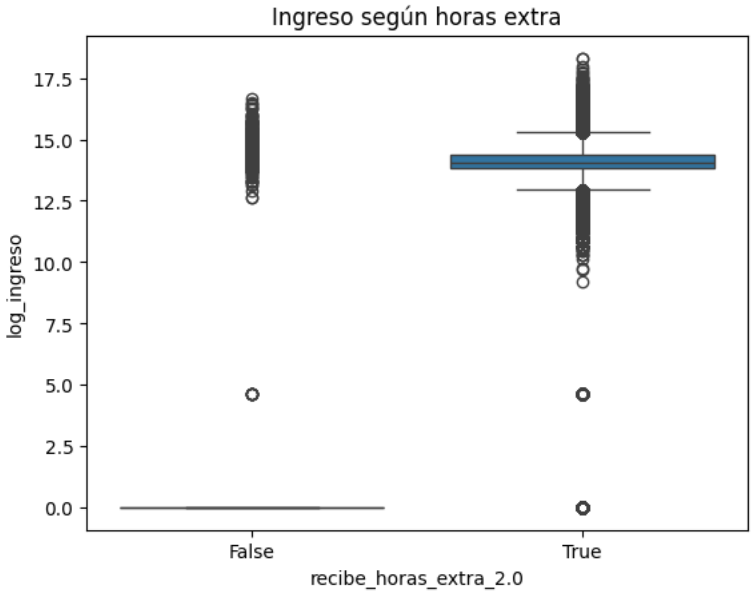

8. Ingreso según sexo

El boxplot de ingreso según sexo (sexo_2) muestra que no existen diferencias relevantes entre los grupos. Tanto la mediana como el rango intercuartílico son muy similares para ambos valores (True y False), lo que indica que la distribución del ingreso es prácticamente igual. Aunque hay valores atípicos en ambos casos, estos se distribuyen de manera similar, sin evidenciar una brecha clara. Esto sugiere que, en este conjunto de datos, el sexo no tiene un impacto significativo en el nivel de ingresos.

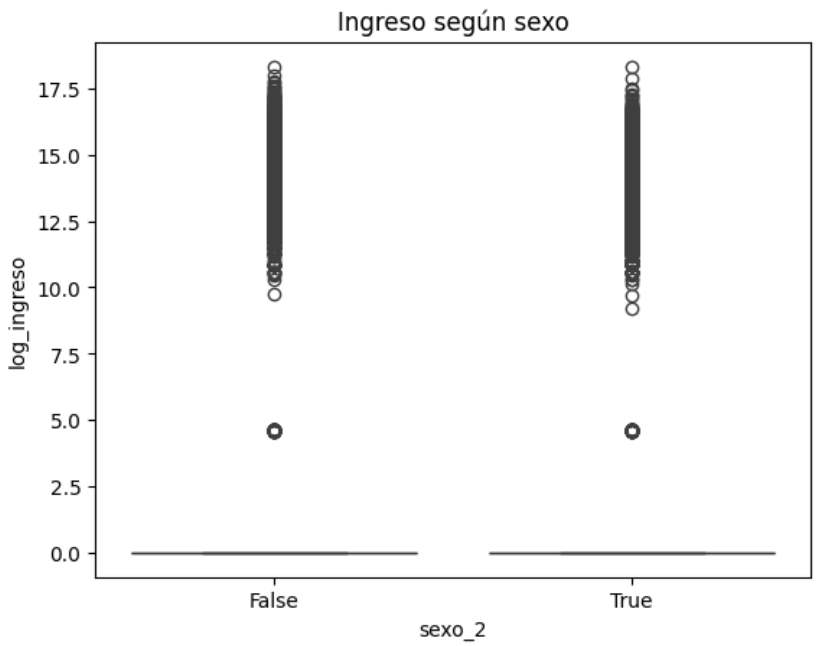

9. Matriz de correlaciones (general)

La matriz de correlación muestra que la relación más fuerte es entre log_ingreso y recibe_horas_extra_2.0 (0.97), indicando una asociación muy alta entre recibir horas extra y tener mayores ingresos. En contraste, la edad presenta una correlación muy baja con el ingreso (0.083), lo que confirma lo observado en la gráfica de dispersión. La variable horas_extra_incluidas tiene una correlación débil con el ingreso (0.16), y cotiza_pension_2.0 también presenta correlaciones bajas con las demás variables. En general, la mayoría de relaciones son débiles, excepto la de horas extra, que destaca como el factor más influyente.

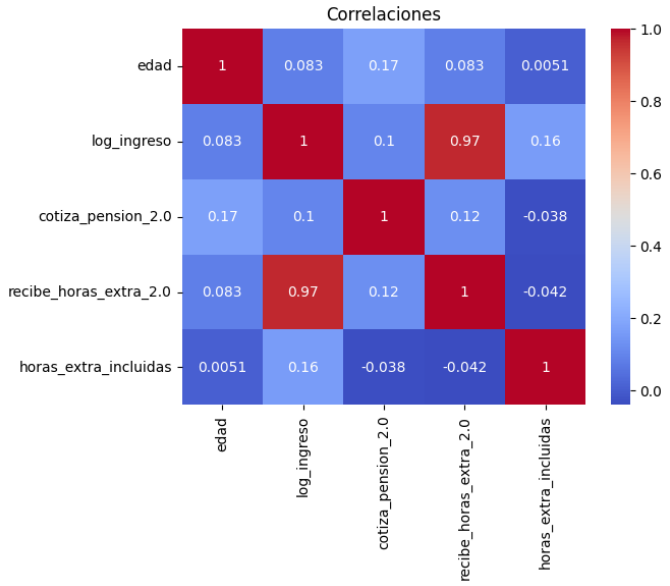

10. Matriz de correlaciones (enfoque en formalidad laboral)
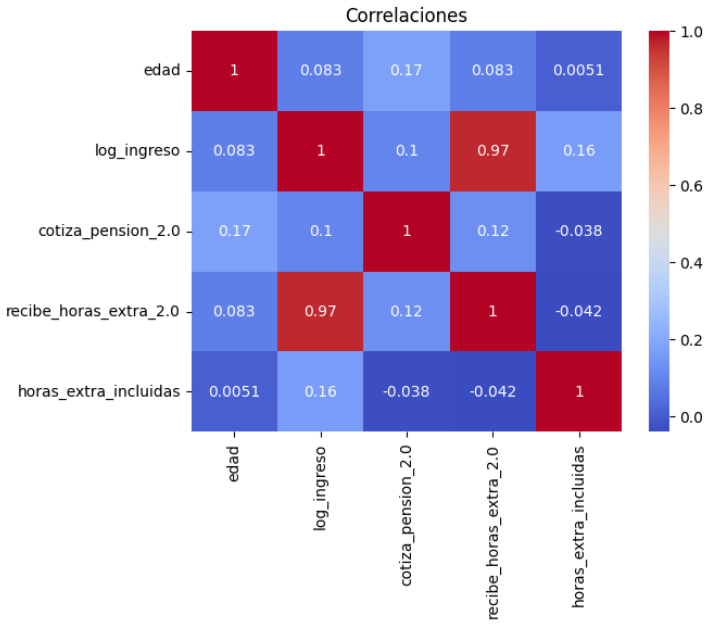
La matriz muestra que la cotización a pensión presenta una correlación positiva pero débil con el ingreso (0.1), lo que indica una ligera asociación entre formalidad laboral y mayores ingresos. En contraste, recibir horas extra tiene una correlación muy alta con el ingreso (0.97), sugiriendo que este factor está fuertemente vinculado a mejores niveles salariales. Por otro lado, la relación entre cotizar pensión y horas extra incluidas es levemente negativa, lo que indica que no todos los indicadores de formalidad están directamente relacionados. En general, algunos aspectos de la formalidad laboral influyen en el ingreso, pero con distinta intensidad.