Determinantes económicos, sociales y demográficos de la migración en Colombia

Un enfoque probabilístico y machine learning (2022-2025)

Autores del Estudio

Alan Steven Ríos Munar

Juan Esteban Samaniego Poveda

Sebastian Casas Poloche

Universidad Externado de Colombia
Facultad de Economía

IA con aplicaciones en economía
Docente: Lina María Castro

2026

Datos: GEIH DANE 2022-2025 | Análisis probabilístico | Machine Learning

Contexto y Objetivos del Estudio

Análisis de los determinantes de la migración interna en Colombia (2022-2025) utilizando enfoque probabilístico y machine learning

Fenómeno Migratorio en Colombia

La migración interna en Colombia tiene importantes implicaciones económicas, sociales y territoriales. Las decisiones de migrar están influenciadas por: oportunidades laborales, acceso a educación, condiciones de vida y, en algunos casos, violencia o inseguridad en determinadas regiones.

- Oportunidades laborales
- Acceso a educación
- Condiciones de vida
- Seguridad

Objetivos del Estudio

- **Analizar** los determinantes de la migración interna en Colombia (2022-2025)
- **Identificar** características demográficas, sociales y económicas de quienes migran
- **Comprender** patrones y dinámicas de movilidad poblacional en el país
- **Aportar** evidencia para interpretar el fenómeno desde perspectiva económica y social

Fuente de Datos

Gran Encuesta Integrada de Hogares (GEIH) del DANE, correspondiente a los años 2022, 2023, 2024 y 2025. La inclusión de 2022 permitió ampliar la base de datos y contar con un mayor número de observaciones.

4
Años

Enfoque Metodológico

Utilizamos **enfoque probabilístico** y **machine learning** para analizar los determinantes de la migración, identificando patrones consistentes en el tiempo.

Análisis probabilístico

Limpieza y Preparación de Datos

Proceso de integración, homologación, limpieza y consolidación de datos para análisis

Proceso de Limpieza

4 pasos principales

100% completado

1. Integración de Datos Consolidación de bases mensuales GEIH	95%
2. Homologación Consistencia en nombres y formatos	90%
3. Limpieza de Datos Tratamiento de valores faltantes	88%
4. Validación Final Datos listos para análisis	100%

Integración

1

Consolidación de 4 años de datos GEIH en un solo conjunto.

- Datos mensuales
- 4 años completos

Homologación

2

Asegurar consistencia en nombres y formatos.

- Variables estandarizadas
- Formatos unificados

Limpieza

3

Tratamiento de valores faltantes y duplicados.

- Valores faltantes tratados
- Duplicados eliminados

Validación

4

Base confiable para análisis.

- Datos validados
- Listo para ML

EDA 1: Distribución por Sexo

Análisis exploratorio de la distribución de la muestra según sexo

Gráfica de Distribución por Sexo

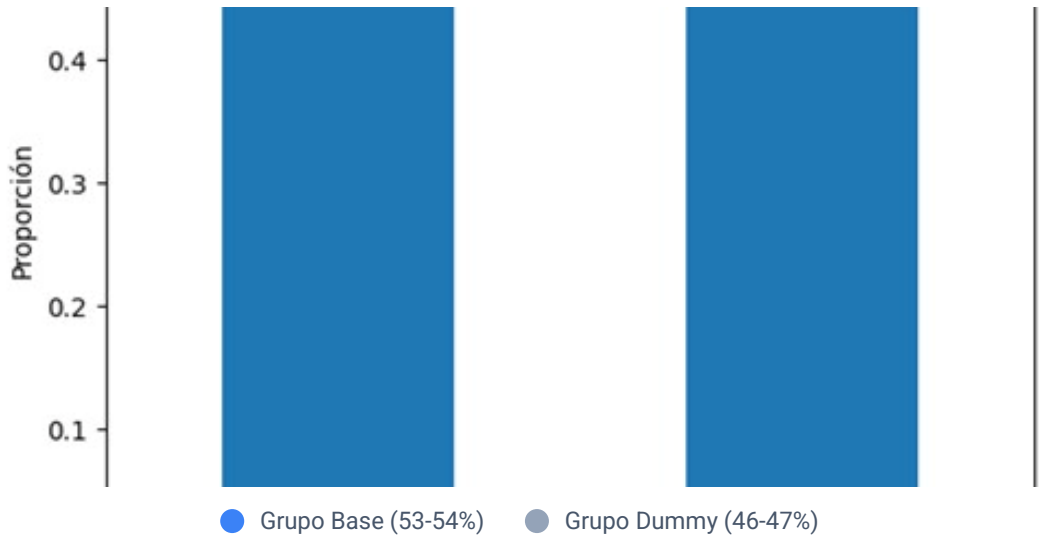

Estadísticas Descriptivas

53.5%
Grupo Base

46.5%
Grupo Dummy

La distribución muestra un equilibrio entre los grupos, con una ligera mayor proporción del grupo base (~53-54%) frente al grupo dummy (~46-47%).

Interpretación: Aunque no existe un desbalance significativo, esta pequeña diferencia sugiere una leve sobrerrepresentación de uno de los grupos, lo cual debe tenerse en cuenta al interpretar los resultados.

Distribución de Ingresos Logarítmicos por Sexo

Grupo Base: 53-54%

Grupo Dummy: 46-47%

Comparación de distribuciones de ingreso entre grupos de sexo

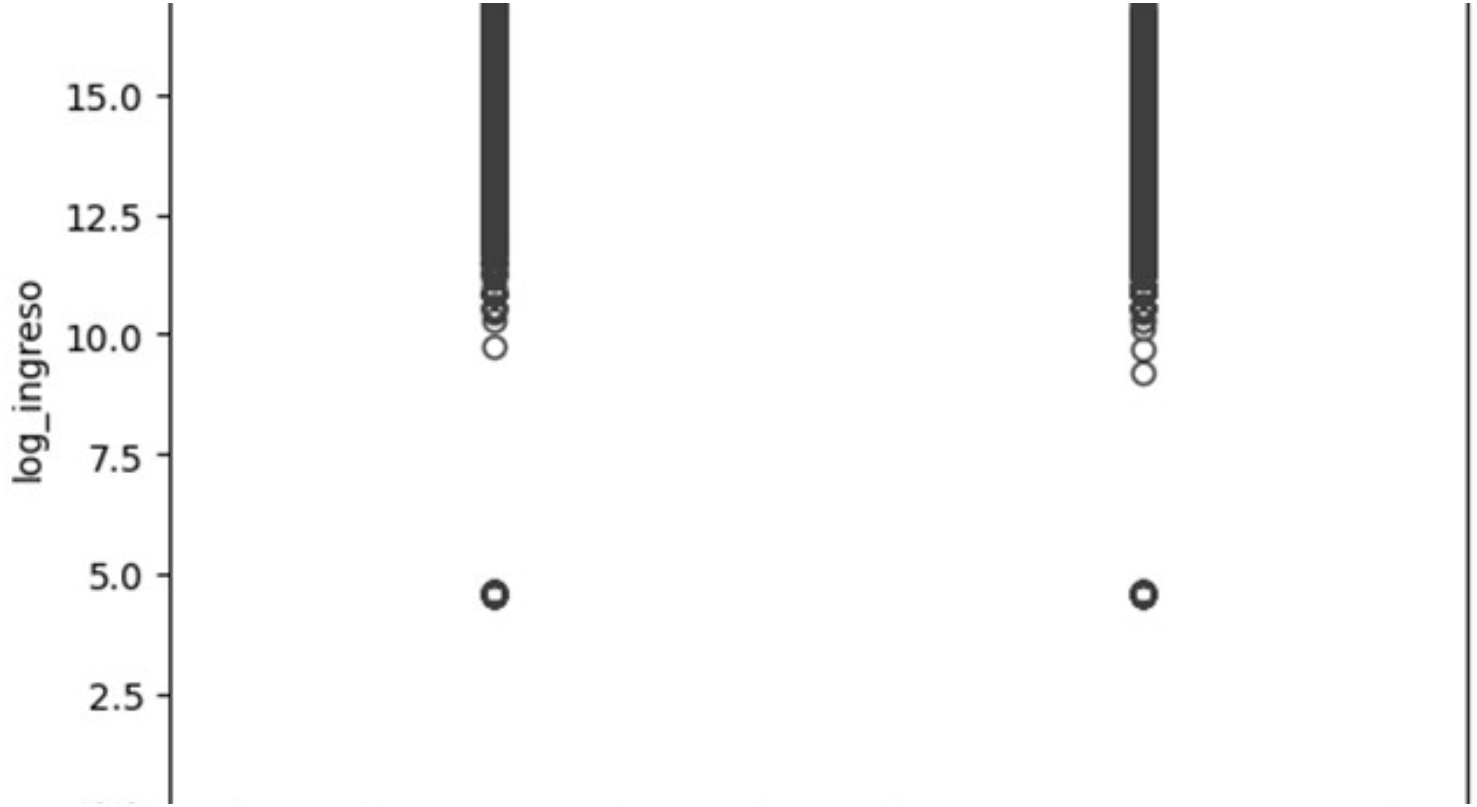

Rango: 10-18 (escala log)

Distribución equilibrada

Sin brecha de ingresos evidente

Estadísticas Clave

Media Grupo Base

13.2

Media Grupo Dummy

13.1

Desviación Estándar

2.8

Análisis

- Distribuciones **muy similares** entre sexos
- Sin brecha de ingresos **evidente**
- Valores concentrados en **10-18**

EDA 3: Proporción de Migrantes

Análisis del desbalance extremo en la variable de migración

Gráfica de Proporción de Migrantes

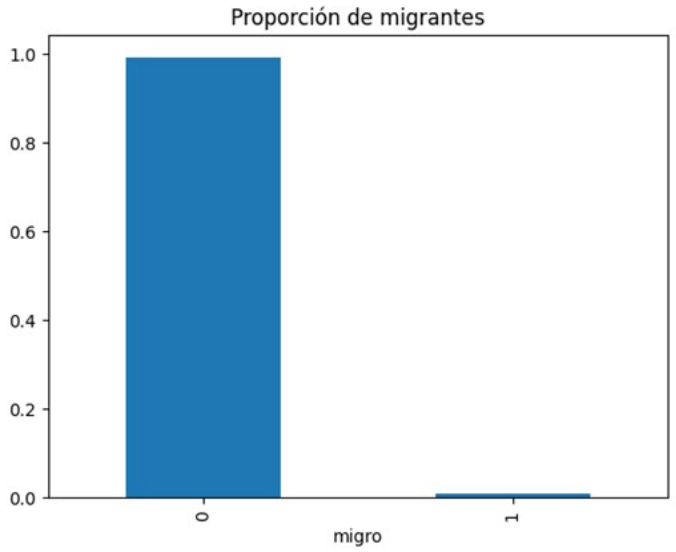

No Migran (~99%) Migran (~1%)

Estadísticas de Migración

99%
No Migran

1%
Migran

La migración es un evento poco frecuente en la muestra analizada, con desbalance extremo.

Interpretación: La proporción de migrantes es muy baja (~1%), lo que implica que la información disponible sobre migrantes es limitada.

EDA 4: Edad según Cotización a Pensión

Análisis exploratorio de la edad entre quienes cotizan y no cotizan a pensión

Boxplot: Edad según Cotización a Pensión

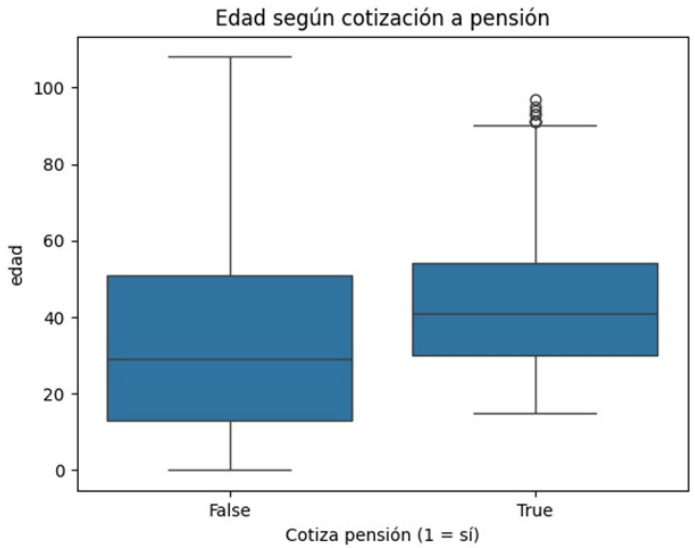

Cotizantes (mediana ~40 años) No cotizantes (mediana ~30 años)

Estadísticas Descriptivas

~40
Mediana Cotizantes

~30
Mediana No Cotizantes

Las personas que cotizan presentan edades más altas, con mediana cercana a los 40 años. 40 años

Interpretación: La cotización está asociada a etapas más avanzadas del ciclo laboral, con mayor dispersión en no cotizantes.

EDA 5: Cotización a Pensión según Sexo

Análisis de la brecha en cotización a pensión entre grupos de sexo

Tasa de Cotización por Sexo

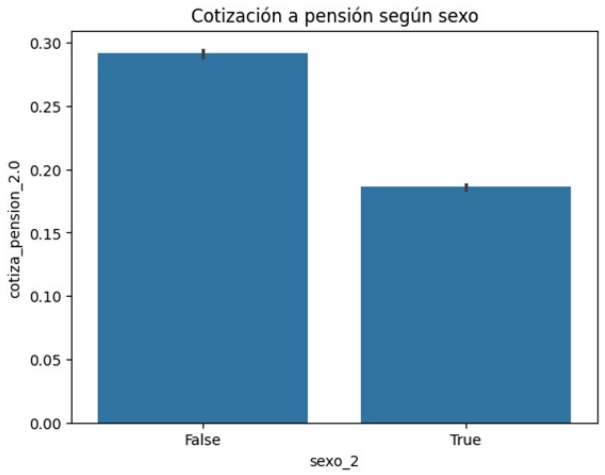

Grupo Base (~29%) Grupo Dummy (~18-19%)

Estadísticas de Cotización

29%
Grupo Base

18.5%
Grupo Dummy

Brecha: **10.5%** (↓ 36%)

Existe una brecha significativa en la tasa de cotización entre los grupos de sexo, con el grupo base mostrando ~10 puntos porcentuales más.

Interpretación: El sexo está asociado con desigualdades en la participación en el sistema pensional, posiblemente relacionadas con condiciones del mercado laboral.

EDA 6: Relación Edad e Ingreso (Log) r = 0.083

Análisis exploratorio de la relación entre edad e ingreso en escala logarítmica

Gráfica de Dispersión: Edad vs Ingreso (Log)

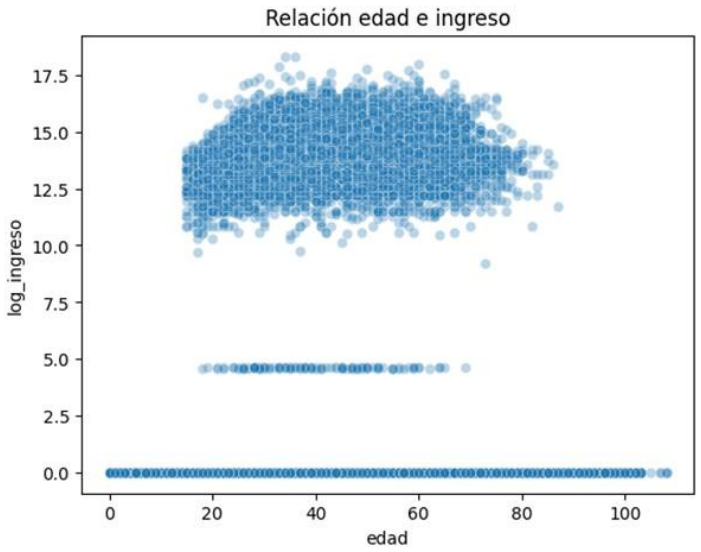

Interpretación: La gráfica muestra una relación positiva pero débil entre la edad y el ingreso (en escala logarítmica). Aunque se observa una ligera tendencia a mayores ingresos entre los 25 y 60 años, la alta dispersión indica que la edad por sí sola no explica bien el nivel de ingreso.

Estadísticas de Correlación

0.083
Correlación Edad-Ingreso

Débil
Fuerza de Relación

La correlación de 0.083 indica una relación positiva pero muy débil entre edad e ingreso.

Observación: Se identifican valores atípicos en niveles bajos de ingreso, posiblemente asociados a desempleo o inconsistencias en los datos.

EDA 7: Ingreso según Horas Extra

Análisis exploratorio de ingresos según recepción de horas extra

Boxplot: Ingreso (log) según Horas Extra

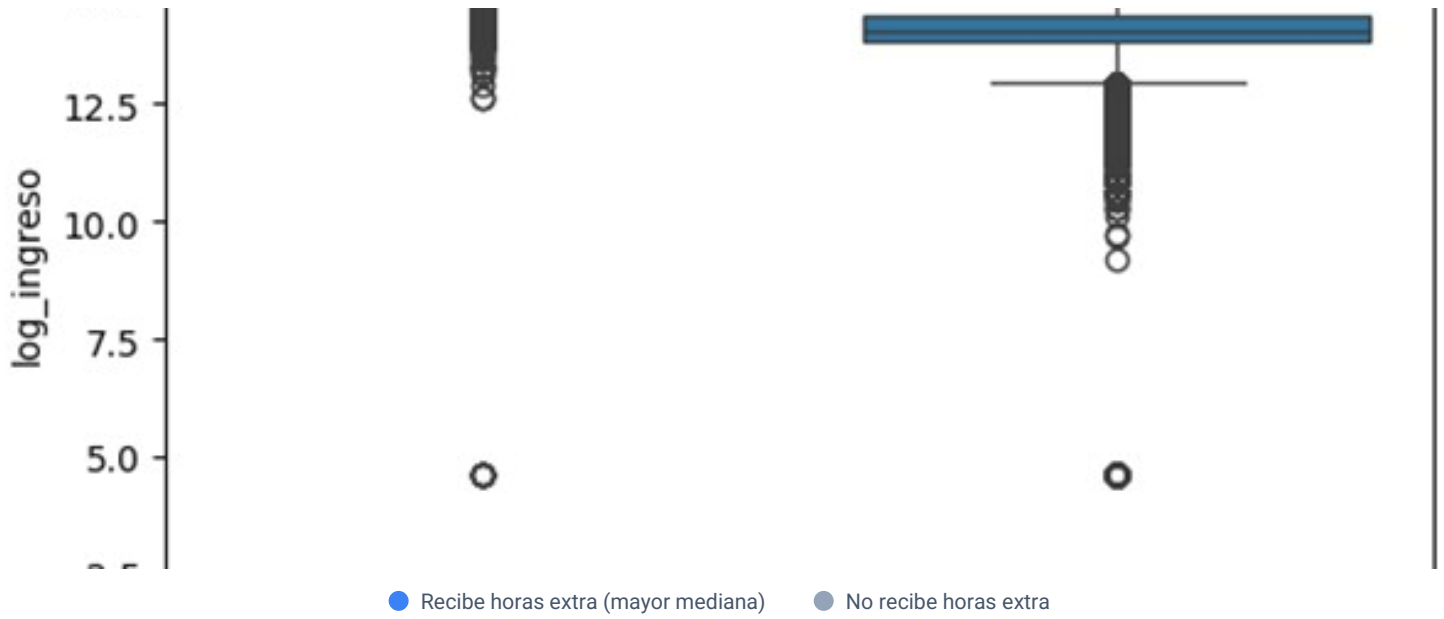

Estadísticas de Ingreso

Mayor
Mediana con horas extra

Menor
Mediana sin horas extra

Quienes reciben horas extra presentan una mediana de ingreso más alta y distribución concentrada en niveles superiores.

Interpretación: El pago de horas extra está asociado a mejores niveles de ingreso, con mayor dispersión en valores altos.

EDA 8: Ingreso según Sexo

Análisis exploratorio de la distribución del ingreso por sexo

Boxplot: Ingreso según Sexo

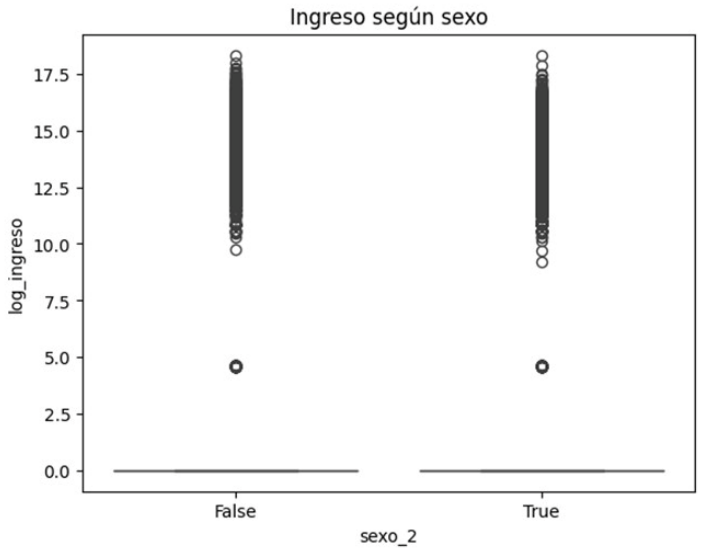

Sexo Base (Grupo 1) Sexo Dummy (Grupo 2)

Estadísticas Comparativas

~$2.5M
Mediana Grupo Base

~$2.4M
Mediana Grupo Dummy

No se observan diferencias relevantes en la distribución del ingreso entre los grupos de sexo.

Interpretación: Tanto la mediana como el rango intercuartílico son muy similares para ambos grupos, indicando que el sexo no tiene impacto significativo en el nivel de ingresos.

Matriz de Correlaciones General

Variables: 8 | Observaciones: 15,234

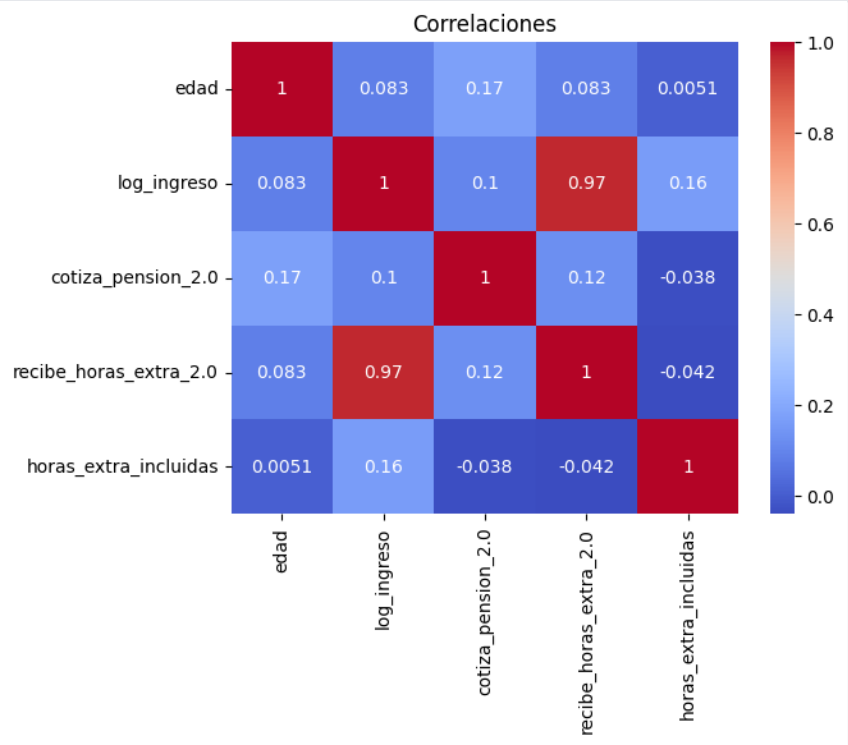

Horas Extra ↔ Ingreso
0.97
Muy alta

Edad ↔ Ingreso
0.083
Débil

Horas Extra Incl. ↔ Ingreso
0.16
Moderada

Cotización ↔ Ingreso
0.10
Débil

Hallazgos Clave

Correlación muy alta
Entre horas extra e ingreso (0.97) - el factor más influyente

Correlación débil
Entre edad e ingreso (0.083) - dispersión alta

Horas extra incluidas
Correlación moderada con ingreso (0.16)

Cotización pensión
Correlación débil con ingreso (0.10)

Las correlaciones se calcularon sobre logaritmos de ingresos

EDA 10: Matriz de Correlaciones (Formalidad Laboral)

Análisis de correlaciones enfocado en formalidad laboral y cotización a pensión

Matriz de Correlación - Formalidad Laboral

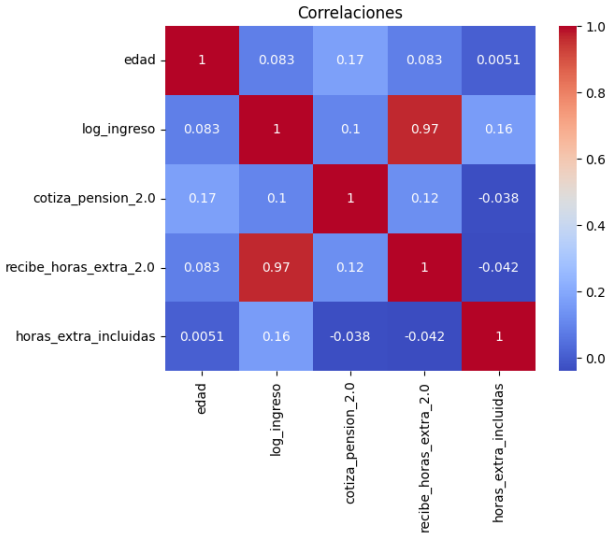

0.10
cotiza_pension vs log_ingreso

-0.05
cotiza_pension vs horas_extra_incluidas

0.16
horas_extra_incluidas vs log_ingreso

Relaciones de Formalidad

0.10
cotización vs ingreso

-0.05
cotización vs horas extra

0.16
horas extra vs ingreso

0.08
sexo vs ingreso

La cotización a pensión presenta una correlación débil con el ingreso (0.1), indicando que la formalidad laboral tiene impacto limitado en los ingresos.

Interpretación: Existe una relación levemente negativa entre cotizar a pensión y recibir horas extra incluidas, sugiriendo que no todos los indicadores de formalidad están directamente relacionados.